Kev 决策查询流程与原理

文本决策推理 · 共享状态前缀 · 问题分支隔离 · 指针概率读出

A 查询主流程

01 输入决策请求
状态 S：待分析的文本
问题 Q：指令与候选项

→

02 规范化与编码
统一任务格式并分词
标记边界、检查长度

→

03 因果骨干前向
共享状态，独立问题行
仅预填充，提取隐状态

→

04 收集读出表示
问题：<decide> 位置
选项：</opt> 位置

→

05 计算候选概率
指针头打分 → 除以 T
Softmax 得到选项分布

→

06 返回结构化结果
判断概率 / 选择 / 评分
按问题编号组织答案

B 共享状态与独立问题分支

当前 Qwen3.5 / Qwen3.8 文本版的在线推理路径

状态 S → 因果预填充 → 共享前缀缓存
注意力 KV + DeltaNet 循环状态与卷积状态

问题分支 Q1	问题分支 Q2	问题分支 Qm
<q> 指令	<q> 指令	<q> 指令
<opt> 候选项 </opt> …	<opt> 候选项 </opt> …	<opt> 候选项 </opt> …
<decide>	<decide>	<decide>
从共享前缀继续因果前向	从共享前缀继续因果前向	从共享前缀继续因果前向
问题表示 + 各候选表示	问题表示 + 各候选表示	问题表示 + 各候选表示

每个分支只读取共享状态与本问题内的先前 token。
各分支的位置编号均从状态末尾继续，问题之间互不可见。
同一问题内的候选项默认按因果顺序可见。

C 指针打分与概率校准

对每个问题 i，在其 K 个候选项内计算

问题隐状态：读取 <decide> 位置
候选隐状态：读取每个 </opt> 位置

$$q_i = Q(h_i^D) \quad k_{ij} = K(h_{ij}^O)$$

Q、K 为可学习线性投影，输出维度为 d_p

$$z_{ij} = k_{ij}^T q_i / \sqrt{d_p}$$

缩放点积得到各候选项的原始分数

$$p_{ij} = \exp(z_{ij} / T) / \Sigma_k \exp(z_{ik} / T)$$

在当前问题的候选项集合内归一化

T > 0 为检查点携带的校准温度。
T 调整分布的尖锐程度，保持本问题的
最大分数候选项不变，各选项概率之和为 1。

D 按任务类型解释同一组候选概率

判断 Noul
候选项为 false / true
输出 p(true)

选择 Choice
候选项为给定类别或动作
输出 argmax_j p_ij 与选项概率

评分 Score
候选项为从低到高的等级
输出 Σ_j j · p_ij，等级从 0 开始

注：图示为当前文本版在线推理。纯注意力骨干也可用分块因果掩码实现问题隔离。
算法直接读取候选概率，不进行逐 token 文本生成；题内选项顺序仍可能影响结果。